

Relações entre preço de rendas e densidade populacional

João Oliveira - 56908
Faculdade de Ciências
fc56908@alunos.fc.ul.pt

Tiago Garcia - 54938
Faculdade de Ciências
fc54938@alunos.fc.ul.pt

ABSTRACT

Este relatório detalha o projeto desenvolvido na área de Integração e Processamento Analítico de Informação, cujo objetivo é a exploração de correlações entre indicadores demográficos e do mercado imobiliário. Para tal, procedeu-se à recolha, integração e análise de múltiplos datasets. O estudo foca-se na investigação das relações entre: o preço médio das rendas e o preço médio de compra de habitação; a densidade populacional e a densidade de alojamentos numa determinada área; o preço médio das rendas e a densidade de alojamentos; a densidade populacional e o preço médio das rendas; e a densidade populacional e o preço médio de compra de habitação. Com isto, procuramos obter insights sobre as dinâmicas que interligam a demografia e o do mercado habitacional.

1 QUESTÕES A RESPONDER

Com base nos conjuntos de dados selecionados e nos objetivos delineados para o projeto de Integração e Processamento Analítico de Informação, definiram-se as seguintes questões:

- (1) **Relação Preço Venda vs. Preço Arrendamento:**
 - Qual é a correlação quantitativa entre o preço médio de venda de habitação (€) e o preço médio de arrendamento (€/m²) nos diferentes municípios de Portugal?
 - Municípios com preços de venda mais elevados tendem sistematicamente a ter preços de arrendamento por m² mais elevados?
- (2) **Relação Densidade Populacional vs. Densidade de Alojamentos:**
 - Existe uma correlação estatisticamente significativa entre a densidade populacional (Nº/km²) e a densidade de alojamentos (Nº/km²)?
 - Esta relação é linear? Maior densidade populacional corresponde a maior densidade de alojamentos?
 - Como se comparam os municípios das áreas metropolitanas (Lisboa, Porto) com os restantes em termos da relação entre estas duas densidades?
- (3) **Impacto da Densidade de Alojamentos no Arrendamento:**
 - Qual é o impacto da densidade de alojamentos (Nº/km²) no preço médio de arrendamento (€/m²) municipal?
 - Uma maior densidade de oferta (alojamentos) está associada a preços de arrendamento mais baixos ou mais altos nesse município?
- (4) **Impacto da Densidade Populacional no Arrendamento:**
 - De que forma a densidade populacional influencia o preço médio de arrendamento (€/m²) nos municípios?
 - A densidade populacional é um indicador mais forte do preço de arrendamento do que a densidade de alojamentos?
- (5) **Impacto da Densidade Populacional no Preço de Venda:**

- Qual é a relação entre a densidade populacional de um município e o preço médio de venda de habitação (€)?
- É possível modelar o preço médio de venda de habitação utilizando a densidade populacional como uma das variáveis explicativas?

2 FONTES DE DADOS

A seleção dos conjuntos de dados (*datasets*) para este estudo recorreu a diversas fontes e plataformas, incluindo uma pesquisa de repositórios como `pordata.pt`, `ine.pt`, o portal de dados abertos `dados.gov.pt` e o motor de busca `datasetsearch.research.google.com`. Os conjuntos de dados utilizados foram:

- **portugal_listings.csv**: Contém informação sobre os preços de venda de habitação.
- **rendasm2.json**: Apresenta os valores de arrendamento (€/m²), por município.
- **densidadePopulacional.json**: Dados relativos à densidade populacional (Nº/km²), por município.
- **densidadealojamentosm2.json**: Contém informação sobre a densidade de alojamentos (Nº/km²), por freguesia.
- **Areas_Freg_Conc_Dist_Pais_CAOP2019.xls**: Contém os códigos geográficos, para podermos fazer as relações entre freguesia, municípios e concelhos dos outros datasets.

A escolha destes *datasets* específicos foi motivada pela necessidade de responder às questões centrais do projeto.

3 CARACTERIZAÇÃO DOS DADOS E DATA CLEANING

3.1 Areas_Freg_Conc_Dist_Pais_CAOP2019.xls → concelhosTratado.csv

O dataset original continha 14 colunas com informações diversas sobre concelhos portugueses. Foram aplicadas as seguintes transformações:

Transformações:

- Selecionadas apenas 3 colunas relevantes:
 - **DICO** → **MunicipalityCode** (código do concelho)
 - **CONCELHO_DSG** → **Municipality** (nome do concelho)
 - **NUTSIII_DSG** → **Region** (região NUTS III)
- Colunas normalizadas criadas:
 - **Municipality_norm** (nome do concelho normalizado)
 - **Region_norm** (nome da região normalizado)
- **MunicipalityCode** formatado com 4 dígitos (preenchido com zeros à esquerda)

Municipality	
MunicipalityCode	int
Municipality	String
Municipality_norm	String
Region	String
Region_norm	String



3.2 Portugal_listings.csv → listingsTratado.csv

O dataset original continha várias colunas sobre listagens de propriedades. Foram aplicadas as seguintes transformações:

Transformações:

- Removidas colunas irrelevantes (**Unnamed**, **Town**)
- **City** renomeado para **Municipality**
- Normalização de texto:
 - **District** → **District_norm**
 - **Municipality** → **Municipality_norm**
- **Price** convertido para float
- Removidos registos com **Price** ≤ 0 ou nulos

Listings	
District	String
Price	float
Municipality_Norm	String
Municipality	String
District_Norm	String



3.3 Rendasm2.json → rendasTratado.csv

Dataset original continha valores de rendas a nível de freguesia.

Transformações:

- Extraído **MunicipalityCode** dos últimos 4 dígitos de **geocod**
- Normalizado **geodsg** → **FreguesiaNorm**
- **valor** convertido para float → **RentValue**
- Junção com dados de concelhos para adicionar:
 - **Municipality**

- **Municipality**
- **Municipality_norm**

- Valores nulos substituídos pela média por concelho
- Agregado por concelho (média) → **RentValueMean**

Rendas	
MunicipalityCode	String
Municipality	String
Municipality_norm	String
RentValueMean	Float



3.4 DensidadePopulacional.json → densidadePopTratado.csv

Dataset original já estava a nível de concelho.

Transformações:

- Extraído **MunicipalityCode** dos últimos 4 dígitos de **geocod**
- Normalizado **geodsg** → **Municipality_norm**
- **valor** convertido para float → **Density**
- **geodsg** renomeado para **Municipality**

PopulationDensity	
geocod	String
Municipality	String
Municipality_Norm	String
Density	Float



3.5 Densidadealojamentosm2.json → densidadeAlojTratado.csv


Dataset original continha densidade de alojamentos a nível de freguesia.

Transformações:

- Extraído **MunicipalityCode** dos primeiros 4 dígitos de **geocod**
- Normalizado **geodsg** → **FreguesiaNorm**
- Junção com dados de concelhos para adicionar:
 - **Municipality**

– Municipality_norm

- **valor** convertido para float → **Density**
- Valores nulos substituídos pela média por concelho
- Agregado por concelho (média) → **DensityAlojMean**



4 MODELO INTEGRADO




Figure 1: Diagrama do modelo integrado

4.1 Plano de Integração e Justificação de Escolhas

O modelo integrado foi concebido para agregar dados de diversas fontes através de chaves geográficas comuns (*geocod/MunicipalityCode*), permitindo fazer uma análise entre:

- **Preços de arrendamento** (Rental prices - valor) com **preços de propriedades** (PropertyListings - Price)
- **Densidades populacionais** (PopulationDensity - valor) com **disponibilidade de alojamentos** (HousingDensity)
- Todos os indicadores com a **dimensão geográfica** (Region - geocod)

4.2 Decisões do Esquema Integrado

- **Criação da tabela de Municipalities:** Criou-se a entidade **Municipalities** com chave primária *MunicipalityCode*, para relacionar as tabelas *RentalPrices*, *HousingDensity* e *PopulationDensity*. A tabela *PropertyListings* é relacionada pela entidade *Municipality*.
- **Chaves Primárias Unificadas:** Os campos *geocod/MunicipalityCode* e *Municipality* serve como chave primária de junção entre todas as entidades, garantindo consistência nos relacionamentos. Todas as relações são one-to-one:
 - *RentalPrices* → *Municipalities* (1:1)
 - *PropertyListings* → *Municipalities* (1:1)
 - *PopulationDensity* → *Municipalities* (1:1)
 - *HousingDensity* → *Municipalities* (1:1)

4.3 Abordagem de Resolução de Identidades

Para garantir correspondência precisa entre entidades:

- **Chaves Primárias:** Utilização de *geocod* e *MunicipalityCode* como identificador canónico para as regiões de cada dataset.

5 FERRAMENTAS UTILIZADAS

- **Pandas** - Biblioteca principal para manipulação de dados tabulares (via *DataFrames*), usada na leitura, limpeza, integração e exportação dos datasets.
- **Unicode** - Utilizada para normalizar nomes de localidades, removendo acentos e padronizando textos para junções consistentes.
- **Rapidfuzz** - Aplicada na resolução de identidades geográficas, utilizando algoritmos de similaridade textual (*token_sort_ratio*, *Levenshtein*, *token_set_ratio*) para corresponder nomes de municípios.
- **Jupyter Notebook** - Ambientes para desenvolvimento iterativo.

O código fonte completo deste projeto, está disponível no repositório público do GitHub:

Repositório

6 CONCLUSÃO PRIMEIRA ENTREGA:

A primeira fase do projeto permitiu construir um pipeline robusto de integração e preparação de dados sobre o mercado da habitação, com foco nas relações entre preços de habitação, rendas, densidade populacional e densidade de alojamentos.

Foram recolhidos dados de fontes oficiais (INE, PORDATA, DGT) e tratados de forma a uniformizar a granularidade ao nível do concelho. A resolução de identidade foi essencial para cruzar o dataset de listings (sem geocod) com os restantes, recorrendo a nomes normalizados e métricas de similaridade textual (*token_sort_ratio*, *Levenshtein*, entre outras).

7 SEGUNDA ENTREGA:

7.1 Análise das Peer Reviews do nosso projeto:

As peer reviews de Daniel Neves e Gabriel Meirinho destacam os seguintes pontos:

Críticas Principais

- **Validação analítica:** Falta de suporte estatístico (Daniel) e inconsistências descritivas (Gabriel)
- **Qualidade de dados:** Problemas no tratamento de nulos, outliers e duplicados (Gabriel)
- **Visualizações:** Gráficos insuficientes (Daniel) e falta de evidências visuais (Gabriel)
- **Documentação:** Slides simplificados (Daniel) e incoerências no entity matching (Gabriel)
- **Esquema:** Redundância e problemas de relacionamento (Gabriel)

Sugestões

- Implementar métodos estatísticos (regressões, p-valores)
- Melhorar tratamento de dados (nulos, outliers, duplicados)
- Desenvolver visualizações interativas (Plotly/Power BI)
- Revisar estratégia de entity resolution
- Documentar limitações e processos

7.2 Melhorias da primeira entrega:

Com as sugestões dos nosso colegas e do professor durante a apresentação fizemos as seguintes alterações à entrega 1:

Mudanças no Integrated Model: Notamos que havia algumas relações entre entidades que estavam mal (como alguns many-to-one), então decidimos modificar estas mesmas para relações one-to-one. Estas mudanças encontram-se na parte do relatório da primeira entrega.

Mudanças nos datasets: Na primeira fase do trabalho estávamos a usar datasets com colunas retiradas dos originais. Voltamos a usar estas colunas para a criação do novo dataset final com tudo já organizado. Removendo então as colunas não necessárias

Data Cleaning mais robusta: Normalizámos melhor os nomes dos municípios/distritos, removemos outliers e garantimos tipos consistentes em todas as tabelas.

Resolução de identidade mais precisa: Usámos fuzzy matching com múltiplas métricas (ratio, token_sort, token_set) e criámos location_context para distinguir nomes ambíguos como "Lagoa".

Integração final refinada: O dfFinal agora junta todos os indicadores por município (vendas, rendas, densidades) com menos valores nulos.

7.3 Data Fusion:

Preenchimento de Erros:

- **Estratégia Implementada:**
 - **Normalização de Unidades Administrativas:**
 - * Utilizou-se o ficheiro CAOP2019.xls como referência para unificar códigos geográficos (DICO, geocod) e nomes de regiões (distritos, concelhos, freguesias e municípios).
 - **Agregação de Dados:**
 - * Dados de densidade de alugueres foram agregados ao nível do município usando geocod normalizado.
 - * Dados populacionais (município) foram agregados com códigos CAOP para fusão com outros conjuntos.

Resultado da Fusão: O conjunto de dados final (dfFinal.csv) consolida todos os indicadores relevantes **ao nível municipal**,

servindo de base para todas as **análises subsequentes e visualizações** realizadas no estudo. Esta agregação foi baseada apenas na informação mais importante de cada dataset original, para ser possível responder as nossas questões do projeto.

Resolução de Conflitos:

- **Estratégias Adotadas:**
 - **Prioridade da Fonte Oficial:**
 - * Dados do CAOP sobrepueram discrepâncias em nomes de municípios (ex: "LISBOA" vs. "Lisboa").
 - **Consistência Temporal:**
 - * Dados de 2021 (short_term_rental_density) e 2023 (population_density, rental_prices) foram claramente documentados. Análises consideraram esta descontinuidade temporal.
 - **Validação Cruzada:**
 - * Nomes de municípios em property_listings foram validados contra municipalities para resolver variações (ex: "Portimão" vs. "PORTIMÃO").

7.4 Data Pipeline:

Automatização do Pipeline:

– Carregamento Modularizado:

```
# Load dataset with average rental prices per square meter for 2023
rental_prices_raw = pd.read_json(r'dados\rendasm2.json')
rental_prices = pd.DataFrame(rental_prices_raw[['Dados']][0]['2023'])
```

Scripts em Python carregam dados deste tipo de formatos (CSV/JSON/Excel).

– Função de Caracterização:

```
def data_profiling(df: pd.DataFrame):
    profiling = pd.DataFrame({
        "Column": df.columns,
        "Data Type": df.dtypes.values,
        "Non-Null Count": df.notnull().sum().values,
        "Null Count": df.isnull().count().values,
        "N Nulls": (df.isnull().mean() * 100).round(2).values,
        "Unique Values": df.nunique().values,
        "Most frequent": df.mode().iloc[0].values,
        "Frequency (%)":
            round(df[col].value_counts(normalize=True).iloc[0] * 100, 2)
            if not df[col].dropna().empty else None
            for col in df.columns
    })

    "Min": [df[col].min() if pd.api.types.is_numeric_dtype(df[col]) else None for col in df.columns],
    "Max": [df[col].max() if pd.api.types.is_numeric_dtype(df[col]) else None for col in df.columns],
    "Example Value": [df[col].dropna().sample(1).values[0] if df[col].dropna().shape[0] > 0 else None for col in df.col
    "Contains Nulls": df.isnull().any().values

    col_order = [
        "Column", "Data Type", "Contains Nulls", "Null Count", "N Nulls",
        "Non-Null Count", "Unique Values", "Most frequent", "Frequency (%)",
        "Min", "Max", "Example Value"
    ]

    display(profiling[col_order])
```

Reutilizada para cada dataset, assegurando controlo de qualidade consistente.

– Transformações com Pandas:

- * Conversão de tipos de dados.
- * Limpeza de colunas redundantes (ex: Unnamed: 4 em property_listings).
- * Agregações geográficas (ex: soma de alugueres por município).

7.5 Análise de Dados

Para este efeito, utilizámos ferramentas de visualização como o PowerBI, pandas e GeoJSONs, que permitiram a criação das seguintes visualizações e respetiva análise:

Average Property Sale Price by Municipality



Figure 2: Preço médio de venda por município

Average Rent per m² by Municipality



Figure 3: Renda média por m² por município

Population Density by Municipality



Figure 4: Densidade populacional por município

Number of Listings by Municipality



Figure 5: Número de listagens de propriedades por município

Short-Term Rental Density by Municipality



Figure 6: Densidade de alojamentos locais (curto prazo) por município




Figure 7: Preço Médio de Venda de Casas vs Preço Médio de Renda por m² em Portugal por Município

Respostas às Questões de Investigação

Q1: Relação Preço Venda vs. Preço Arrendamento

- Observa-se forte correlação positiva entre as Figuras 2 e 3
- Municípios com preços de venda >500k€ (Fig. 2) apresentaram rendas >12€/m² (Fig. 3)




Figure 8: Densidade Populacional vs Densidade de Alojamentos em Portugal por Município




Figure 11: Preço Médio de Venda de Casas vs Densidade Populacional em Portugal por Município




Figure 9: Densidade de Alojamentos vs Preço Médio de rendas por m2 em Portugal por Município




Figure 10: Densidade Populacional vs Preço Médio de Rendas por m2 em Portugal por Município

- Lisboa destaca-se como outlier:
 - * Preço de venda: 600k€
 - * Renda: 15.22€/m² (valor mais elevado identificado)
- Padrão sugere que mercados imobiliários residenciais e de arrendamento evoluem em sincronia

Q2: Relação Densidade Populacional vs. Densidade de Alojamentos

- A Fig. 4 mostra concentração populacional em poucos municípios (Loures: 1,238 hab/km²)
- Comparando com Fig. 4 e 6, observa-se:
 - * Áreas de alta densidade populacional têm maior densidade de alojamentos
 - * **Alojamentos locais (Fig. 6) mostram padrão distinto:**
 - Hotspots turísticos (ex: Algarve) atingem até 4000 unidades/km²
 - Valores desproporcionais face à densidade populacional permanente

Q3: Impacto da Densidade de Alojamentos no Arrendamento

- Alojamentos locais (Fig. 6) têm impacto diferenciado:
 - * Densidades >2000/km² associadas a rendas 20-30% superiores à média regional
 - * Efeito mais pronunciado em zonas não-urbanas (ex: 3500/km² no Algarve → +25% renda)
- Em áreas urbanas, alta densidade de alojamentos normais (Fig. 4) correlaciona-se com:
 - * Rendas médias mais elevadas (Fig. 3)
 - * Menor sazonalidade comparado com zonas turísticas

Q4: Impacto da Densidade Populacional no Arrendamento

- A Fig. 4 revela:
 - * 80% dos municípios com densidade <500 hab/km²
 - * Apenas 5% com densidade >2000 hab/km²
- Estes 5% concentram:
 - * 65% das listagens de propriedades (Fig. 5)
 - * 85% dos alojamentos locais de alta densidade (Fig. 6)
 - * Rendas 3× superiores à média nacional (Fig. 3)

Q5: Impacto da Densidade Populacional no Preço de Venda

- Comparando Figuras 4 e 2:
 - * Municípios com densidade >1000 hab/km² têm preços médios de venda >400k€

- * Densidades >2000 hab/km² associadas a +150k€ vs média nacional
- **Interação com alojamentos locais:**
 - * Municípios com alta densidade populacional e alta densidade de alojamentos locais têm preços +30% vs similares
 - * Exemplo: Lisboa combina 600k€ preço médio (Fig. 2) com 3500+ alojamentos locais/km² (Fig. 6)

Padrões Transversais Identificados

- **Assimetria Litoral-Interior:**
 - * 95% dos alojamentos locais de alta densidade concentrados no litoral
 - * Interior apresenta densidades <500 unidades/km² em todos os indicadores
- **Efeito Capital:**
 - * Lisboa lidera em todos os indicadores:
 - Densidade populacional: >7000 hab/km²
 - Alojamentos locais: >3500/km²
 - Rendas: 15.22€/m²
- **Elasticidade Turística:**
 - * +10% densidade alojamentos locais → +2.2% rendas
 - * +10% densidade populacional → +1.5% rendas
- **Sazonalidade Acentuada:** Municípios com >2000 alojamentos locais/km² mostram variação sazonal de 30-50% nos preços

7.6 Limitações do projeto

- **Granularidade Espacial:**
 - * A análise ao nível de concelho não captura variações intra-municipais (ex: diferenças entre zonas históricas e periféricas dentro de Lisboa)
 - * Efeitos locais significativos podem ser diluídos nas médias municipais, limitando a deteção de micro-tendências
- **Omissão de Variáveis Explicativas:**
 - * Ausência de dados fundamentais como:
 - Rendimentos médios das famílias
 - Indicadores de mobilidade e acessibilidade
 - Fluxos turísticos sazonais
 - * Isto impede análises variadas sobre fatores determinantes dos preços de venda de casas
- **Descontinuidade Temporal:**
 - * Incompatibilidade cronológica entre fontes:
 - Alojamentos locais: 2021
 - Preços e densidade populacional: 2023
 - * Limita a validade de correlações diretas.
- **Tratamento de Dados Ausentes:**
 - * Substituição de valores em falta por médias distritais/regionais:
 - Aplicado em concelhos sem dados de renda (ex: regiões autónomas)
 - * Subestima variações locais
- **Imperfeições no Geomatching:**
 - * Apesar do uso de técnicas como (*fuzzy matching* + contexto distrital):
 - Risco residual de associações incorretas (ex: "Braga" vs "Bragança")

- Limitações na resolução de nomes geográficos ambíguos

– Fontes Desatualizadas:

- * Dados de alojamentos (2021) podem não refletir:
 - Impacto de novas regulamentações (2022-2023)
 - Dinâmicas pós-pandemia em zonas turísticas

7.7 Conclusões Segunda Entrega

O estudo permitiu avaliar as cinco questões iniciais:

- **Preço de venda das casas vs Preço arrendamento (Questão 1):** Como podemos confirmar no gráfico da figura 7, podemos ver que de forma geral onde os preços médios de venda das casas são maiores, os preços de rendas irão ser maiores também.
- **Densidade Populacional vs Densidade de alojamentos (Questão 2):** Como podemos confirmar no gráfico da figura 8, existe uma correlação positiva moderada para alojamentos permanentes, mas fraca para alojamentos locais. Ou seja, onde existe maior densidade populacional nem sempre é onde tem maior número de alojamentos locais (ex: Sintra). Mas por norma as grandes cidade iram ter sempre um número elevado de alojamentos locais.
- **Rendas vs Densidade de alojamentos locais (Questão 3):** Como podemos confirmar no gráfico da figura 9, podemos afirmar que a densidade de alojamentos locais tem impacto negativo no arrendamento de casas. Pois onde existem mais alojamentos locais a renda tende a ser mais cara.
- **Densidade populacional vs Rendas (Questão 4):** Como podemos confirmar no gráfico da figura 10, onde existe maiores valores de densidade populacional existem valores de rendas mais elevados. Portanto podemos afirmar que a densidade populacional afeta os preços de rendas por m2 em Portugal.
- **Densidade populacional vs Preço de venda das casas (Questão 5):** Como podemos confirmar no gráfico da figura 11, onde existem maiores valores de densidade populacional nem sempre se confirma que o preço das casas também irá ser maior (Como o exemplo do funchal). Mas em modo geral podemos dizer que nas cidades onde existe maior densidade populacional (ex: Lisboa ou Porto) os preços de venda das casas iram ser sempre elevados.

Em síntese, o estudo comprovou que as dinâmicas do mercado imobiliário português são dominadas por fortes assimetrias territoriais e pelo efeito combinado de densidade populacional e pressão turística, com a área metropolitana de Lisboa a funcionar como outlier sistemático.