

Datasets

Os *datasets*, no geral, provêm de fontes oficiais e os seus metadados estão disponíveis. No entanto, o *dataset* Portugal listings não é transferido corretamente da sua fonte, dado que o original possui 25 colunas e o *dataset* utilizado para o projeto tem apenas 14, das quais são utilizadas 3. Sugiro que, para terem mais profundidade e tirarem conclusões, transfiram o *dataset* na sua totalidade primeiro e só depois verificarem o que pode ser útil para o projeto. Nem todos os *datasets* são provenientes de fontes distintas, tal como é dito no *notebook* (ex: 3 *datasets* provêm do INE).

Esquema Integrado

Existe alguma redundância em ter as colunas originais e as finais no esquema integrado final (na análise poderá fazer sentido mas no esquema é redundante). No diagrama não foram interligados os campos normalizados mas no trabalho os mesmos foram utilizados na maioria das operações. Na secção de justificações do esquema integrado não existem realmente justificações, apenas se expõe o que se fez. O nome das tabelas do esquema integrado não estão em concordância com as tabelas anteriormente mostradas (Rendas - *RentalPrices*). As tabelas de relevância existem apesar de serem incoerentes com o trabalho face com o que é ou não relevante, não estando de acordo com o relatório. Vários códigos não se podem relacionar com apenas 1, dado que cada código individual é apenas 1. Nem todas as relações são *1 to many*, dado que é possível verificar outros tipos de ligação.

Fraquezas e pontos fortes do Projeto

Não está claro no relatório se estamos a debater o preço de compra ou preço de venda das propriedades, dado que o resumo se refere à primeira e o restante relatório à segunda. No relatório não existe uma descrição dos processos de *blocking* e de *entity matching*, existindo apenas algumas referências nas secções 5 e 6. Na secção de *Entity Resolution*, não se referem exatamente ao que vão realizar, apenas à tipologia das chaves. Neste sentido, devem investir na informação que possui no *notebook* para que esteja explicada no relatório. Não existem secções dedicadas ao *Data Profiling* nem *Data Cleaning* no relatório (apenas falam em tirar os nulos ≤ 0 e normalizar). Onde está o tratamento de duplicados? Tratamentos diferentes para diferentes valores nulos. Colunas com 2% de nulos = 90% de nulos.

O parágrafo mais fraco do trabalho é o seguinte: “*Para garantir correspondência precisa entre entidades: • ChavesPrimárias: Utilização de geocod e MunicipalityCode como identificador canónico para as regiões de cada dataset.*”

As razões desta escolha devem-se essencialmente à falta de coerência. Refere-se que a resolução de identidades utiliza *geocod* e *municipalitycode*, o que por si só é incorreto devido ao facto de ser um *match* exato e não uma associação de palavras sintaticamente diferentes com o mesmo sentido semântico. Do mesmo modo, a implementação usa como chaves os nomes dos municípios normalizados e não os códigos. Adicionalmente gostaria de referir que no mesmo relatório, mais concretamente nas secções, ferramentas utilizadas e conclusão, é dito que para a resolução de entidades foram utilizados os nomes dos municípios como chave, adicionando ainda mais incoerência a este processo. No *notebook*, fica dúvida a utilização do termo Alojamento, dado que no relatório não se faz menção a serem alojamentos locais. Nem todos os municípios são considerados como sendo parte de zonas urbanas, pelo que é necessário ter cuidado com essa denominação.

Existe um problema a nível de mostrar os dados durante o *notebook*. Por exemplo, não é possível fazer *data profiling* sem mostrar recorrentemente se os valores nulos estão resolvidos. O mesmo se pode dizer a nível das conversões de tipo e da limpeza de dados. No *data cleaning*, existem

operações que não são justificadas: porquê eliminar valores nulos em casos específicos, sendo que se poderia dar *fill* com outros dados? Não existem conclusões claras no que toca ao *data profiling*, não se sabendo ao certo como cada *dataset* limpo se encontra ao nível de número de valores únicos, duplicados. Realizam operações e fazem afirmações (ex: que existem inconsistência dos separadores “.” e “,” mas nunca é claro como chegam a estas conclusões. Uma sugestão seria mostrar pequenas amostras - por exemplo, através da função *head* - do conteúdo dos datasets a serem trabalhados, ao longo do projeto.

Devem demonstrar uma atenção superior aos valores nulos, dado que vários datasets limpos ainda os possuem. Em casos geográficos, podem dar *fill* a esses valores nulos - se assim for possível - com a média da região. Do mesmo modo, seria importante verificar a presença de *outliers* ou valores discrepantes, dado que ainda persistem situações extremas (ex: uma casa foi vendida por 1 euro (Faro, Loulé) = 11499). O *fill* de valores nulos no campo da densidade de alojamento por concelho não é útil por duas razões: não existem nulos e se cada valor de densidade corresponde a 1 concelho, não existe média de concelhos. Uma sugestão seria alterar o sistema de média por concelho por média de distrito.

O *entity matching* é feito com as 4 primeiras letras do nome do município proveniente das colunas normalizadas mas os resultados mostrados através da função *display* não são referentes a essas colunas. Analisando os *scores* das medidas de semelhança, é possível visualizar que os *matches* corretos são apenas aqueles em que o nome normalizado é o mesmo, derrotando o seu propósito. Na presente amostra os *matches* abaixo de score 1 são incorretos, pelo que o *threshold* teria sempre de ser igual a 1, o que não é viável. Isto demonstra que as medidas de semelhança não estão a funcionar e o objetivo do *entity matching* não é cumprido. Adicionalmente, a implementação do *blocking* não se demonstra eficaz, dado que não são incluídos, por exemplo, os campos referentes ao preço das habitações. Assim, não é possível responder às questões propostas.

O *notebook* é genericamente repetitivo no seu conteúdo, pelo que podem eliminar essas redundâncias ou colocar as vossas conclusões no fim de cada secção, devidamente identificada. A pergunta central do *notebook* não chega a ser a mesma que a do relatório. Considero um ponto bastante positivo as hiperligações no relatório para os datasets, facilitou a busca pelos mesmos. Os temas trabalhados neste projeto são relevantes e a integração de datasets é uma boa via para os resolver.

Questões

O que este projeto trata é alojamentos locais ou alojamentos no sentido mais geral da palavra (habitação)?

Quais os critérios de eficácia para as métricas escolhidas e porquê que são relevantes?

Porque é que quando mostram os *matches* com o maior score as colunas que escolheram para mostrar são colunas distintas das que foram utilizadas na resolução de entidades?

Avaliação

Rigor - 2

Complexity - 3

Clarity - 2

Overall - 2